# МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МОЭВМ

#### ОТЧЕТ

по лабораторной работе №4 по дисциплине «Машинное обучение»

Тема: Ассоциативный анализ

Студент гр. 8304	Кирьянов Д.И
Преподаватель	Жангиров Т. Р.

Санкт-Петербург 2021

### Цель работы

Ознакомиться с методами ассоциативного анализа из библиотеки MLxtend.

## Ход работы

#### Загрузка данных

Создан Python скрипт. Загружены данные в датафрейм

	Item(s)	Item 1	Item 2	 Item 30	Item 31	Item 32
Θ	4	citrus fruit	semi-finished bread	NaN	NaN	NaN
1	3	tropical fruit	yogurt	NaN	NaN	NaN
2	1	whole milk	NaN	NaN	NaN	NaN
3	4	pip fruit	yogurt	NaN	NaN	NaN
4	4	other vegetables	whole milk	NaN	NaN	NaN
9830	17	sausage	chicken	NaN	NaN	NaN
9831	1	cooking chocolate	NaN	NaN	NaN	NaN
9832	10	chicken	citrus fruit	NaN	NaN	NaN
9833	4	semi-finished bread	bottled water	NaN	NaN	NaN
9834	5	chicken	tropical fruit	NaN	NaN	NaN

Рис 1 – Загруженные данные

Получен список всех уникальных товаров. Выведен список товаров, а также их количество.

```
{'cake bar', 'grapes', 'rolls/buns', 'oil', 169
```

Рис 2 – Список товаров и их количество

Полный список: {'cake bar', 'grapes', 'rolls/buns', 'oil', 'specialty cheese', 'decalcifier', 'spread cheese', 'sound storage medium', 'salad dressing', 'sausage', 'bathroom cleaner', 'whole milk', 'cleaner', 'pickled vegetables', 'toilet cleaner', 'pasta', 'specialty fat', 'flower (seeds)', 'soft cheese', 'berries', 'specialty chocolate', 'tea', 'other vegetables', 'detergent', 'cookware', 'bags', 'rum', 'waffles', 'honey', 'curd', 'artif. sweetener', 'pip fruit', 'liquor', 'syrup', 'cat food', 'meat', 'organic products', 'bottled beer', 'salt', 'candy', 'brown bread', 'abrasive cleaner', 'canned fish', 'whisky', 'citrus fruit', 'hard cheese', 'candles', 'frozen vegetables', 'canned beer', 'pastry', 'female sanitary products', 'butter milk', 'flower soil/fertilizer', 'curd cheese', 'rice', 'baby cosmetics', 'finished products', 'jam', 'ketchup', 'popcorn', 'instant coffee', 'coffee', 'frozen chicken', 'dessert', 'soap', 'bottled water',

'pudding powder', 'meat spreads', 'canned vegetables', 'house keeping products', 'ready soups', 'brandy', 'sliced cheese', 'hamburger meat', 'yogurt', 'white bread', 'beef', 'chicken', 'dental care', 'frankfurter', 'specialty vegetables', 'skin care', 'prosecco', 'pork', 'beverages', 'margarine', 'fish', 'rubbing alcohol', 'condensed milk', 'whipped/sour cream', 'shopping bags', 'onions', 'dog food', 'potato products', 'hygiene articles', 'kitchen towels', 'cream cheese', 'frozen fish', 'Instant food products', 'liqueur', 'tidbits', 'canned fruit', 'mustard', 'UHT-milk', 'male cosmetics', 'white wine', 'turkey', 'cooking chocolate', 'frozen fruits', 'herbs', 'liver loaf', 'organic sausage', 'kitchen utensil', 'spices', 'seasonal products', 'butter', 'dishes', 'processed cheese', 'light bulbs', 'ice cream', 'softener', 'soups', 'soda', 'sweet spreads', 'nuts/prunes', 'napkins', 'domestic eggs', 'potted plants', 'frozen dessert', 'frozen potato products', 'make up remover', 'semi-finished bread', 'packaged fruit/vegetables', 'sauces', 'specialty bar', 'cream', 'cling film/bags', 'dish cleaner', 'vinegar', 'red/blush wine', 'baking powder', 'zwieback', 'cereals', 'pet care', 'chocolate', 'misc. beverages', 'newspapers', 'chocolate marshmallow', 'photo/film', 'chewing gum', 'sparkling wine', 'root vegetables', 'fruit/vegetable juice', 'roll products', 'ham', 'preservation products', 'hair spray', 'mayonnaise', 'tropical fruit', 'flour', 'sugar', 'baby food', 'liquor (appetizer)', 'cocoa drinks', 'salty snack', 'nut snack', 'long life bakery product', 'snack products', 'frozen meals'}

# FPGrowth и FPMax Преобразованы данные к виду, удобному для анализа:

	Instant food products	UHT-milk	 yogurt	zwieback
0	False	False	False	False
1	False	False	True	False
2	False	False	False	False
3	False	False	True	False
4	False	False	False	False
9830	False	False	False	False
9831	False	False	False	False
9832	False	False	True	False
9833	False	False	False	False
9834	False	False	False	False

Рис 3 – Преобразованные данные

Проведен ассоциативный анализ используя алгоритм FPGrowth при уровне поддержки 0.03:

```
support
                                         itemsets
    0.082766
                                   (citrus fruit)
                                      (margarine)
    0.058566
   0.139502
                                         (yogurt)
                                 (tropical fruit)
   0.104931
   0.058058
                                         (coffee)
58 0.033249
                             (pastry, whole milk)
59 0.047382 (root vegetables, other vegetables)
                    (root vegetables, whole milk)
60 0.048907
                            (sausage, rolls/buns)
61 0.030605
                 (whipped/sour cream, whole milk)
62 0.032232
```

Рис 4 – Результат FPGrowth при minSup=0.03

Проанализированы получившиеся варианты. Определены минимальное и максимальное значения для уровня поддержки для набора из 1,2:

```
len 1 min: 0.03040162684290798
len 1 max: 0.25551601423487547
len 2 min: 0.030096593797661414
len 2 max: 0.07483477376715811
```

Рис 5 – Анализ полученных данных

Проведен аналогичный анализ используя алгоритм FPMax:

support itemsets	support	
0.030402 (specialty chocolate)	0.030402	0
0.031012 (onions)	0.031012	1
0.032944 (hygiene articles)	0.032944	2
0.033249 (berries)	0.033249	3
0.033249 (hamburger meat)	0.033249	4
0.033452 (UHT-milk)	0.033452	5
0.033859 (sugar)	0.033859	6
0.037112 (dessert)	0.037112	7
0.037417 (long life bakery product)	0.037417	8
0.037824 (salty snack)	0.037824	9
0.038434 (waffles)	10 0.038434	10

```
0.039654
                                    (cream cheese)
   0.042095
                                     (white bread)
13 0.042908
                                         (chicken)
   0.048094
                              (frozen vegetables)
  0.049619
                                       (chocolate)
15
   0.052364
                                         (napkins)
16
  0.052466
                                            (beef)
17
18
  0.053279
                                            (curd)
19 0.055414
                                          (butter)
20 0.057651
                                            (pork)
21 0.058058
                                          (coffee)
  0.058566
                                       (margarine)
22
  0.058973
23
                                     (frankfurter)
                                   (domestic eggs)
24
  0.063447
25 0.064870
                                     (brown bread)
  0.032232
                 (whipped/sour cream, whole milk)
26
                          (fruit/vegetable juice)
27
   0.072293
  0.030097
28
                          (whole milk, pip fruit)
                                     (canned beer)
   0.077682
29
   0.079817
                                      (newspapers)
30
                                    (bottled beer)
31
   0.080529
32 0.030503
                       (citrus fruit, whole milk)
33
   0.033249
                             (pastry, whole milk)
  0.030605
                            (sausage, rolls/buns)
34
35
  0.098526
                                   (shopping bags)
36 0.035892
               (tropical fruit, other vegetables)
                     (tropical fruit, whole milk)
   0.042298
37
  0.047382
              (root vegetables, other vegetables)
38
                    (root vegetables, whole milk)
   0.048907
39
                      (bottled water, whole milk)
   0.034367
  0.034367
                             (yogurt, rolls/buns)
41
   0.043416
                       (yogurt, other vegetables)
42
  0.056024
                             (yogurt, whole milk)
43
   0.032740
                         (soda, other vegetables)
44
                                (soda, rolls/buns)
   0.038332
                               (soda, whole milk)
   0.040061
                   (rolls/buns, other vegetables)
   0.042603
47
   0.056634
                         (rolls/buns, whole milk)
48
  0.074835
                   (whole milk, other vegetables)
49
```

Рис 6 – Результат FPMax

Был проведен анализ полученных данных:

len 1 min: 0.03040162684290798 len 1 max: 0.09852567361464158 len 2 min: 0.030096593797661414 len 2 max: 0.07483477376715811

Рис 7 – Анализ полученных данных

Результаты для наборов длины 2 не изменились. FPMax — это вариант FPGrowth, в который входят только максимальные наборы элементов. Набор элементов максимальный, если он является частым и не встречается такого частого супер-шаблона, содержащего его.

Построена гистограмму для каждого товара. Отображен результат только для 10 самых встречаемых товаров:




Рис 8 – Гистограмма для каждого товара

# Проведен анализ FPGrowth и FPMax для нового набора данных:

	support	itemsets			
Θ	0.082766	(citrus fruit)			
1	0.139502	(yogurt)			
2	0.104931	(tropical fruit)			
3	0.255516	(whole milk)			
4	0.193493	(other vegetables)			
5	0.183935	(rolls/buns)			
6	0.080529	(bottled beer)			
7	0.110524	(bottled water)			
8	0.174377	(soda)			
9	0.088968	(pastry)			
10	0.108998	(root vegetables)			
11	0.077682	(canned beer)			
12	0.093950	(sausage)			
13	0.098526	(shopping bags)			
14	0.071683	(whipped/sour cream)			
15	0.057651	(pork)			
16	0.030503	(whole milk, citrus fruit)			
17	0.056024	(whole milk, yogurt)			
18	0.034367	(rolls/buns, yogurt)			
19	0.043416	(other vegetables, yogurt)			
20	0.035892	(tropical fruit, other vegetables)			
21	0.042298	(tropical fruit, whole milk)			
22	0.074835	(other vegetables, whole milk)			
23	0.042603	(other vegetables, rolls/buns)			
24	0.056634	(rolls/buns, whole milk)			
25	0.034367	(whole milk, bottled water)			
26	0.038332	(rolls/buns, soda)			
27	0.040061	(soda, whole milk)			
28	0.032740	(other vegetables, soda)			
29	0.033249	(pastry, whole milk)			
30	0.047382	(root vegetables, other vegetables)			
31	0.048907	(root vegetables, whole milk)			
32	0.030605	(rolls/buns, sausage)			
33	0.032232	(whipped/sour cream, whole milk)			

Рис 9 – FPGrowth для нового набора данных

len 1 min: 0.05765124555160142 len 1 max: 0.25551601423487547 len 2 min: 0.030503304524656837 len 2 max: 0.07483477376715811

Рис 10 – Анализ полученных данных

	support	itemsets
Θ	0.057651	(pork)
1	0.032232	(whipped/sour cream, whole milk)
2	0.077682	(canned beer)
3	0.080529	(bottled beer)
4	0.030503	(whole milk, citrus fruit)
5	0.033249	(pastry, whole milk)
6	0.030605	(rolls/buns, sausage)
7	0.098526	(shopping bags)
8	0.035892	(tropical fruit, other vegetables)
9	0.042298	(tropical fruit, whole milk)
10	0.047382	(root vegetables, other vegetables)
11	0.048907	(root vegetables, whole milk)
12	0.034367	(whole milk, bottled water)
13	0.034367	(rolls/buns, yogurt)
14	0.043416	(other vegetables, yogurt)
15	0.056024	(whole milk, yogurt)
16	0.032740	(other vegetables, soda)
17	0.038332	(rolls/buns, soda)
18	0.040061	(soda, whole milk)
19	0.042603	(other vegetables, rolls/buns)
20	0.056634	(rolls/buns, whole milk)
21	0.074835	(other vegetables, whole milk)

Рис 11 – FPMах для нового набора данных

len 1 min: 0.05765124555160142 len 1 max: 0.09852567361464158 len 2 min: 0.030503304524656837 len 2 max: 0.07483477376715811

Рис 12 – Анализ полученных данных

Построен график изменения количества получаемых правил от уровня поддержки.




Рис 13 – График изменения количества правил от поддержки для разных длин наборов

1 - красный, 2 - зеленый, 3 - синий, 4 - черный, 5 - оранженый.

#### Ассоциативные правила

Проведен ассоциативный анализ:

	antecedents	consequents	 leverage	conviction
0	(yogurt)	(whole milk)	0.009183	1.070481
1	(yogurt)	(other vegetables)	0.005150	1.033172
2	(tropical fruit)	(yogurt)	0.013156	1.102890
3	(tropical fruit)	(other vegetables)	0.008804	1.076706
4	(tropical fruit)	(whole milk)	0.005359	1.052495
5	(other vegetables)	(whole milk)	0.006849	1.036649
6	(whole milk)	(other vegetables)	0.006849	1.025026
7	(rolls/buns)	(whole milk)	-0.012801	0.930450
8	(bottled water)	(whole milk)	-0.010177	0.913309
9	(bottled water)	(soda)	0.007832	1.061153
10	(citrus fruit)	(whole milk)	-0.001349	0.984313
11	(citrus fruit)	(other vegetables)	0.008135	1.091192
12	(root vegetables)	(other vegetables)	0.028050	1.273671
13	(root vegetables)	(whole milk)	0.014031	1.141049
14	(sausage)	(rolls/buns)	0.010985	1.102730
15	(sausage)	(whole milk)	-0.011477	0.894062
16	(sausage)	(other vegetables)	-0.002776	0.975687
17	(whipped/sour cream)	(whole milk)	0.011419	1.189023
18	(whipped/sour cream)	(other vegetables)	0.015557	1.232002
19	(pastry)	(whole milk)	 0.002304	1.027179

Рис 14 – Результаты анализа

Расчет проводится на основе метрики "confidence"

confidence - confidence( $A \rightarrow B$ ) =  $\frac{\text{support}(A \rightarrow B)}{\text{support}(A)}$ . Вероятность увидеть консеквент в транзакции при условии, что оно также содержит антецедент. Метрика не является симметричной и направленной. Значение 1- максимальное для правила  $A \rightarrow B$ , если консеквент и антецедент всегда встречаются вместе.

lift - lift( $A \rightarrow B$ ) =  $\frac{\text{confidence}(A \rightarrow B)}{\text{support}(B)}$ . Насколько чаще предшествующее и последующее действие правила  $A \rightarrow B$  встречается вместе, чем ожидалось, если бы они были статически независимыми. Lift = 1, если A и B независимы.

leverage - leverage( $A \rightarrow B$ ) = support( $A \rightarrow B$ ) – support(A)×support(B). Разница между наблюдаемой частотой появления A и B вместе и частотой, которую можно ожидать, если A и B были бы независимыми. При leverage = 0 предметы независимы.

conviction - conviction  $(A \rightarrow B) = \frac{1 - \text{support}(B)}{1 - \text{confidence}(A \rightarrow B)}$ . Насколько консеквент сильно зависит от антецедента. При conviction = 1 предметы независимы.

Рассчитаны среднее значение, медиана и СКО для каждой метрики:

support Mean: 0.07468477957805385 Median: 0.06695529601288763 Std: 0.022549155077774167 confidence Mean: 0.2895787148360594 Median: 0.2644391408114558 Std: 0.10368277946597466 Mean: 1.0429974993487907 Median: 1.0560808232246663 Std: 0.1832639607239429 leverage Mean: 0.015533118831358378 Median: 0.01359374637587954 Std: 0.006063340549426105 conviction Mean: 1.0171997189136908 Median: 1.022850930928648 Std: 0.08399289113954451

Рис 15 – Результаты вычислений

Построен граф для следующего анализа:




Рис 16 – Граф анализа

# Вывод

Ознакомились с ассоциативного частотного анализа из библиотеки MLxtend.

#### ПРИЛОЖЕНИЕ А

#### Исходный код программы

```
from mlxtend.frequent patterns import fpgrowth, fpmax, association rules
import matplotlib.pyplot as plt
all data = pd.read csv('groceries - groceries.csv')
print(all data) #Видно, что датафрейм содержит NaN значения
np data = all data.to numpy()
np data = [[elem for elem in row[1:] if isinstance(elem,str)] for row in
np data]
unique items = set()
result = fpgrowth(data, min support=0.03, use colnames = True)
result['length'] = result['itemsets'].apply(lambda x: len(x))
result 1 = result[result['length'] == 1]
print("len 1 min:", min(result_1['support']))
print("len 1 max:", max(result_1['support']))
print("len 2 min:", min(result_2['support']))
print("len 2 max:", max(result 2['support']))
result = fpmax(data, min support=0.03, use colnames=True)
print("len 1 min:", min(result_1['support']))
print("len 1 max:", max(result_1['support']))
print("len 2 min:", min(result_2['support']))
print("len 2 max:", max(result_2['support']))
plt.tight layout()
plt.show()
np data = all data.to numpy()
```

```
np data = [[elem for elem in row[1:] if isinstance(elem,str) and elem in
data_ = pd.DataFrame(te_ary, columns=te.columns)
result = fpgrowth(data , min support=0.03, use colnames = True)
print(result)
result 1 = result[result['length'] == 1]
print("len 1 min:", min(result_1['support']))
print("len 1 max:", max(result_1['support']))
result 2 = result[result['length'] == 2]
print("len 2 max:", max(result 2['support']))
result = fpmax(data , min support=0.03, use colnames=True)
print(result)
result['length'] = result['itemsets'].apply(lambda x: len(x))
result 1 = result[result['length'] == 1]
print("len 1 min:", min(result_1['support']))
print("len 1 max:", max(result_1['support']))
result 2 = result[result['length'] == 2]
print("len 2 max:", max(result 2['support']))
     arr = []
         results = fpgrowth(data, min support=minSup, use colnames=True,
plt.show()
np data = all data.to numpy()
items] for row in np_data]
np_data = [row for row in np_data if len(row) > 1]
data = pd.DataFrame(te_ary, columns=te.columns_)
result = fpgrowth(data, min_support=0.05, use_co
metrics = ["support", "confidence", "lift", "leverage", "conviction"]
```

```
G.add_edge(l, r, label=label, weight=w)
pos = nx.spring_layout(G)
plt.figure()
nx.draw_networkx(G, pos, with_labels=True)
nx.draw_networkx_edges(G, pos, width=list([G[n1][n2]['weight'] for n1, n2 in
G.edges]))
nx.draw_networkx_edge_labels(G, pos,edge_labels=dict([((n1, n2),
f'{G[n1][n2]["label"]}') for n1, n2 in G.edges]), font_color='black')
plt.show()
```